Multi-Model AI 추론 운영 인프라 구축 및 최적화

요약

GPU 한 장에서 대화형 AI 와 이미지 인식 AI 를 함께 운영하면, 두 서비스가 GPU 를 번갈아 사용하느라 응답 목표를 지키며 처리할 수 있는 요청 수가 절반 이하로 감소합니다.
원인을 실험으로 확인했고, 장비를 추가하지 않고 설정 변경만으로 처리 용량을 1.5~2 배 높였습니다.

- **문제**: 함께 운영하면 이미지 인식 AI 의 처리 용량은 3 분의 1, 대화형 AI 는 절반으로 감소
- **결과**: 설정 변경으로 대화형 AI 용량 1.5 배, 함께 운영 중 이미지 인식 AI 용량 2 배. 서버 장애 시 작업 유실 0 건(기존 1 건)
- **남은 과제**: 개선의 대가로 CPU 사용률이 84%로 증가해 다음 한계가 됨. 장애 시 사용자 대기 발생.

문제

비용을 줄이기 위해 GPU 서버 한 대에서 대화형 AI(LLM)와 이미지 인식 AI(CV)를 함께 운영하는 상황을 가정했습니다. 대화형 AI 는 답변을 수 초 동안 한 글자씩 생성하며 GPU 를 계속 사용하고, 이미지 인식 AI 는 이미지 한 장을 수십 밀리초 안에 처리합니다. 두 서비스가 GPU 를 공유할 때 어느 쪽이 얼마나 느려지는지, 원인은 무엇인지, 장비 추가 없이 개선할 수 있는지 확인했습니다.

성능은 응답 목표를 지키면서 받을 수 있는 초당 최대 요청 수인 **처리 용량**으로 비교했습니다.

응답 목표는 요청의 95%가 대화형 AI 는 첫 글자를 1 초 안에, 이미지 인식 AI 는 결과를 0.5 초 안에 받고, 실패율은 1% 이하인 것입니다.

접근 방식

실제 서비스와 같은 구조를 클라우드 GPU 서버(AWS, NVIDIA T4 16 GB) 한 대에 구성했습니다.
각 AI 를 따로 운영할 때와 함께 운영할 때의 처리 용량을 요청량을 늘려 가며 비교했고,
원인 후보 5 개는 결과를 미리 예측해 기록한 뒤 설정을 하나씩 바꿔 검증했습니다.
운영 중 이미지 인식 서버를 강제로 중단해 경보, 복구, 데이터 유실 여부도 확인했습니다.

주요 결과

함께 운영하면 두 서비스의 처리 용량이 모두 감소했고, 설정 변경으로 추가 비용 없이 용량을 개선했습니다.

구분	따로 운영	함께 운영	개선 후	개선 내용
이미지 인식 AI	75	25	50	이미지 처리 프로그램(워커)을 1 개에서 2 개로 증설
대화형 AI	8	4	12	동시에 처리하는 요청 수를 32 개에서 64 개로 확대

수치는 초당 요청 수.
'함께 운영'은 상대 서비스 요청을 고정한 값(대화형 AI 초당 4 건, 이미지 인식 AI 초당 25 건)입니다.

원인: 두 AI 가 GPU 한 장을 번갈아 사용하기 때문입니다.
대화형 AI 는 요청이 초당 2 건만 있어도 GPU 사용 시간의 99%를 점유하므로,
대화형 AI 요청을 줄여도 이미지 인식 AI 는 계속 GPU 사용 순서를 기다려야 합니다.

장애 대응: 이미지 인식 서버가 중단되자 약 20 초 만에 경보가 발생했습니다.
기본 구성에서는 처리 중이던 작업 1 건이 유실되어, 재시작 시 작업을 다시 처리하는 방식(작업 보존)을 적용했고 같은 장애에서 유실 0 건을 확인했습니다.
다만 재시작 후 약 1 분간 쌓인 요청 때문에 응답 시간이 22 초까지 증가했습니다.

리스크

채택한 두 개선은 추가 장비 없이 처리 용량을 높였지만, 그 대가로 다른 자원의 여유를 사용합니다.

변경 내용	개선	리스크
대화형 AI 동시 처리 수 32 → 64 개	처리 용량 1.5 배	글자 생성 간격이 24ms 에서 최대 36ms 로 증가. 목표(50ms) 이내지만 여유 감소
이미지 처리 프로그램 1 → 2 개	함께 운영 중 처리 용량 2 배	CPU 사용률이 84%로 증가해 다음 한계가 됨. 대화형 AI 글자 생성 간격 9% 증가, GPU 메모리 0.4 GB 추가 사용

이와 별도로 GPU 경합 자체와 장애 시 사용자 대기(수십 초)는 해결되지 않은 과제로 남아 있습니다.
측정은 합성 트래픽과 작은 모델을 기준으로 했으므로, 실제 운영에서는 성능 저하가 더 클 수 있습니다.

향후 개선 방향

단기 과제는 장애 시 사용자 대기를 줄이는 것이고,
중기 과제는 GPU 를 번갈아 쓰는 방식 자체를 바꾸는 것입니다.

시기	과제	기대 효과
단기	장애 시 요청 즉시 거절(fail fast)과 자동 재시작, 두 개선을 합친 구성 재측정	장애 중 대기 감소, 운영 설정 확정
중기	GPU 를 번갈아 쓰지 않는 구성 (GPU 동시 실행 기능 또는 GPU 분리) 검토	경합 자체를 제거. GPU 추가 비용과 비교 필요
중기	실제 트래픽과 더 큰 모델로 재측정, CPU 증설 검토	실제 운영 용량 산정